

Budapest University of Technology and Economics

Faculty of Electrical Engineering and Informatics Department of Automation and Applied Informatics

Medical data processing with graph neural networks

Master's Thesis

 $Author \\ Anna Gergály$

Advisor dr. Luca Szegletes

Contents

| Kivonat | | | | | | | |
|------------------------|-------|------------|--------------------------------------|----|--|--|--|
| \mathbf{A} | bstra | ct | | ii | | | |
| 1 | Intr | oducti | ion | 1 | | | |
| | 1.1 | Motiva | vation | 1 | | | |
| | 1.2 | My ap | pproach | 1 | | | |
| | 1.3 | Struct | ture | 1 | | | |
| 2 | Bac | Background | | | | | |
| | 2.1 | Graph | n Neural Networks | 2 | | | |
| | | 2.1.1 | Neural Networks | 2 | | | |
| | | 2.1.2 | Working on Graph Data | 2 | | | |
| | | | 2.1.2.1 Common tasks | 2 | | | |
| | | 2.1.3 | Graph Neural Network Types | 2 | | | |
| | | | 2.1.3.1 Graph Convolutional Networks | 2 | | | |
| | | | 2.1.3.2 Graph Attention Networks | 2 | | | |
| | 2.2 | Medic | cal data | 2 | | | |
| | | 2.2.1 | Medical imaging | 2 | | | |
| | | 2.2.2 | fMRI imaging | 2 | | | |
| | | | 2.2.2.1 Technical background | 2 | | | |
| | | | 2.2.2.2 Clinical significance | 2 | | | |
| 3 Technical background | | | | 3 | | | |
| | 3.1 | Deep | Learning Frameworks | 3 | | | |
| | | 3.1.1 | Pytorch | 3 | | | |
| | | 3.1.2 | DGL | 3 | | | |
| | 3.2 | Using | fMRI data | 3 | | | |
| | | 3.2.1 | Data formats | 3 | | | |
| | | 3 2 2 | Pre-processing | 3 | | | |

| | | 3.2.3 | Extracting ROI Values and Connectomes | 3 | | | | | |
|----|----------------------------|--------|---------------------------------------|---|--|--|--|--|--|
| 4 | Methods and Implementation | | | | | | | | |
| | 4.1 | Graph | Neural Networks on Connectomes | 4 | | | | | |
| | | 4.1.1 | Dataset | 4 | | | | | |
| | | 4.1.2 | Methodology | 4 | | | | | |
| | | 4.1.3 | Results | 5 | | | | | |
| | | 4.1.4 | Conclusions | 5 | | | | | |
| | 4.2 | Conne | ctome-based diffusion | 5 | | | | | |
| | | 4.2.1 | Dataset | 5 | | | | | |
| | | 4.2.2 | Methodology | 5 | | | | | |
| | | 4.2.3 | Results | 5 | | | | | |
| | | 4.2.4 | Conclusions | 5 | | | | | |
| | 4.3 | Minim | ising device-to-device differences | 5 | | | | | |
| | | 4.3.1 | Dataset | 5 | | | | | |
| | | 4.3.2 | Methodology | 5 | | | | | |
| | | 4.3.3 | Results | 5 | | | | | |
| | | 4.3.4 | Conclusions | 5 | | | | | |
| 5 | Future work | | | | | | | | |
| | 5.1 | Future | e work | 6 | | | | | |
| | 5.2 | Conclu | asions | 6 | | | | | |
| A | cknov | wledge | ments | 7 | | | | | |
| Bi | Bibliography 8 | | | | | | | | |

HALLGATÓI NYILATKOZAT

Alulírott Gergály Anna, szigorló hallgató kijelentem, hogy ezt a diplomatervet meg nem engedett segítség nélkül, saját magam készítettem, csak a megadott forrásokat (szakirodalom, eszközök stb.) használtam fel. Minden olyan részt, melyet szó szerint, vagy azonos értelemben, de átfogalmazva más forrásból átvettem, egyértelműen, a forrás megadásával megjelöltem.

Hozzájárulok, hogy a jelen munkám alapadatait (szerző(k), cím, angol és magyar nyelvű tartalmi kivonat, készítés éve, konzulens(ek) neve) a BME VIK nyilvánosan hozzáférhető elektronikus formában, a munka teljes szövegét pedig az egyetem belső hálózatán keresztül (vagy autentikált felhasználók számára) közzétegye. Kijelentem, hogy a benyújtott munka és annak elektronikus verziója megegyezik. Dékáni engedéllyel titkosított diplomatervek esetén a dolgozat szövege csak 3 év eltelte után válik hozzáférhetővé.

| Budapest, 2025. március 8. | |
|----------------------------|--------------|
| | |
| | |
| | |
| | Gergály Anna |
| | hallgató |

Kivonat

Jelen dokumentum egy diplomaterv sablon, amely formai keretet ad a BME Villamosmérnöki és Informatikai Karán végző hallgatók által elkészítendő szakdolgozatnak és diplomatervnek. A sablon használata opcionális. Ez a sablon IATEX alapú, a TeXLive TEXimplementációval és a PDF-IATEX fordítóval működőképes.

Abstract

This document is a LATeX-based skeleton for BSc/MSc theses of students at the Electrical Engineering and Informatics Faculty, Budapest University of Technology and Economics. The usage of this skeleton is optional. It has been tested with the *TeXLive* TeX implementation, and it requires the PDF-LATeX compiler.

Introduction

- 1.1 Motivation
- 1.2 My approach
- 1.3 Structure

Background

- 2.1 Graph Neural Networks
- 2.1.1 Neural Networks
- 2.1.2 Working on Graph Data
- 2.1.2.1 Common tasks
- 2.1.3 Graph Neural Network Types
- 2.1.3.1 Graph Convolutional Networks
- 2.1.3.2 Graph Attention Networks
- 2.2 Medical data
- 2.2.1 Medical imaging
- 2.2.2 fMRI imaging
- 2.2.2.1 Technical background
- 2.2.2.2 Clinical significance

Technical background

- 3.1 Deep Learning Frameworks
- 3.1.1 Pytorch
- 3.1.2 DGL
- 3.2 Using fMRI data
- 3.2.1 Data formats
- 3.2.2 Pre-processing
- 3.2.3 Extracting ROI Values and Connectomes

Methods and Implementation

4.1 Graph Neural Networks on Connectomes

4.1.1 Dataset

The ABIDE (Autism Brain Imaging Data Exchange) dataset focuses on the furthering research into ASD (autism spectrum disorder) through neuro-imaging and neuroscience. The dataset contains in total 1112 resting state fMRIs of subjects both with ASD (539 individuals) and typically developing controls (573 individuals).

The imaging data has been collected by 16 institutions, who collaborated to create a publicly accessible anonymised dataset to allow the broader scientific community to take part in ASD related research while preserving the privacy of the participants. As such, datasets do not contain any protected health information.

Since fMRI preprocessing techniques are very complex image processing operations and heavily resource intensive, an initiative also formed to provide a preprocessed version of the dataset.

Since there is not a widely accepted best practice method for preprocessing fMRI images, the participating five teams have all used their preferred methods to clean the data. The participants have also provided a ROI activation timeseries calculated using 7 different brain atlases from each type of the preprocess method.

The very close ratio of affected vs control subjects (539 to 573) means the dataset is well-balanced in terms of a classification task on the diagnosis of subjects.

4.1.2 Methodology

In the paper [?] by Wang et al. researchers worked with the ABIDE dataset to create a graph convolutional network based architecture for predicting the diagnosis of a patient based on the resting state fMRI.

- 4.1.3 Results
- 4.1.4 Conclusions
- 4.2 Connectome-based diffusion
- 4.2.1 Dataset
- 4.2.2 Methodology
- 4.2.3 Results
- 4.2.4 Conclusions
- 4.3 Minimising device-to-device differences
- 4.3.1 Dataset
- 4.3.2 Methodology
- 4.3.3 Results
- 4.3.4 Conclusions

Future work

- 5.1 Future work
- 5.2 Conclusions

Acknowledgements

Ez nem kötelező, akár törölhető is. Ha a szerző szükségét érzi, itt lehet köszönetet nyilvánítani azoknak, akik hozzájárultak munkájukkal ahhoz, hogy a hallgató a szakdolgozatban vagy diplomamunkában leírt feladatokat sikeresen elvégezze. A konzulensnek való köszönetnyilvánítás sem kötelező, a konzulensnek hivatalosan is dolga, hogy a hallgatót konzultálja.

Bibliography

[] Lebo Wang, Kaiming Li, and Xiaoping P Hu. Graph convolutional network for fmri analysis based on connectivity neighborhood. *Network Neuroscience*, 5(1):83–95, 2021.